

Auditoria Técnica — SCM Analytics

Sistema de previsão de partidas (Copa do Mundo 2026). Análise de arquitetura, modelo matemático, dados, código e riscos. Ênfase no modelo.

Auditoria técnica independente

20 de junho de 2026

Contents

1	Método e escopo da auditoria	3
2	1. Visão geral do projeto	4
2.1	O que é	4
2.2	Como funciona — fluxo principal	4
2.3	Módulos e como se relacionam	4
3	2. Arquitetura	6
3.1	Organização de pastas	6
3.2	Coesão e acoplamento	6
3.3	Escalabilidade	6
3.4	Manutenibilidade	6
3.5	Melhorias arquiteturais sugeridas	7
4	3. Modelos matemáticos (ênfase)	8
4.1	3.1 Elo (elo_engine.py) — sólido, mas sem recência	8
4.2	3.2 Poisson (predictor.poisson_reads/markets) — correto, mas independente	8
4.3	3.3 Curva de empate C1 (predictor.draw_prob) — corrigida, mas in-sample	8
4.4	3.4 Saldo $f(dr)$, total $g(dr)$ e o piso de λ — forma linear inválida no tail	9
4.5	3.5 Incerteza e propagação (features_pit + predictor.elo_direct_read) — elegante, parcialmente inerte	9
4.6	3.6 Ensemble (predictor.predict) — diversidade redundante	9
4.7	3.7 Altitude (altitude.py) — maior alavanca; adotada; ainda extrapolada	10
4.8	3.8 Fatores rejeitados — corretamente barrados pelo portão	10
4.9	3.9 Confiança (predict_match.confidence) — desenho bom, maturidade quase inerte	10
4.10	3.10 Tamanho do sinal — verificação independente do resultado-título	10
4.11	3.11 Modelos estatísticos mais robustos (o que seria superior, e por quê)	11
5	4. Fontes de dados	12
6	5. Qualidade do código	13
7	6. Regras de negócio	14
8	7. Problemas encontrados	15
9	8. Melhorias (priorizadas por impacto)	18
10	9. Funcionalidades futuras (com justificativa)	19
11	10. Roadmap (ordem de prioridade)	20

12.11. Conclusão	21
12.1 Pontos fortes (com justificativa técnica)	21
12.2 Pontos fracos (com justificativa técnica)	21
12.3 O que mais chamou a atenção	21
12.4 Nível técnico	21
12.5 Preparo para análises da Copa 2026	22
13 Anexo A — Verificações numéricas executadas	23

1 Método e escopo da auditoria

Este documento é uma auditoria técnica independente do repositório **SCM Analytics**, na função de arquiteto de software e auditor técnico. **Não implementei funcionalidades:** li, reproduzi numericamente e critiquei. Toda conclusão cita o arquivo/módulo em que se baseia; onde uma informação não foi encontrada, declaro-o explicitamente.

O que foi lido. Todo o *vault* Obsidian (00 - Projeto a 06 - Analises): README.md, CLAUDE.md, MODELO_FINAL.md, TECH_STACK.md, o contrato matemático camada1-planejamento-v5.md e o camada1-apendice-formas-v5.md, todas as 11 notas de 02 - Modelos/, as notas de dados (Fontes gratuitas, Esquema SQLite), e as **duas auditorias anteriores** do próprio projeto (Auditoria técnica externa 2026-06-18 e Auditoria técnica completa 2026-06-19). Todo o pacote Python **scm_analytics/scm/** (25 módulos .py, ~4.118 linhas), os testes (tests/, 25 arquivos, 128 funções) e os dados (dados/).

O que foi verificado em código (marcado [verificado]). Reconstruí o pipeline a partir do *snapshot* dados/results.csv (martj42, 49.431 jogos ingeridos) num ambiente isolado e **reproduzi as fórmulas centrais e o backtest** — incluindo o resultado-título do projeto (bate o Elo público com $IC > 0$). Detalhe no Anexo A.

Relação com as auditorias internas. O projeto já passou por duas auditorias próprias. Esta auditoria **(a) confirma no código atual o que foi corrigido, (b) sinaliza o que continua aberto e (c) adiciona achados novos** que as rodadas anteriores não destacaram — em particular um **erro direcional na Camada 3 (desfalques)** e um **import ausente** em altitude.py, ambos verificados.

Limitação do ambiente. O arquivo dados/scm.sqlite (42 MB) **não pôde ser lido** neste ambiente — retorna *“database disk image is malformed”* tanto direto quanto após cópia. Reconstruí a base do zero a partir do CSV para todas as verificações. Isto é coerente com a *quirk* de FS documentada pelo próprio projeto (D-14/D-16), mas significa que **não validei o artefato binário entregue**, apenas o que o código gera a partir da fonte.

2 1. Visão geral do projeto

2.1 O que é

O SCM Analytics é um **sistema local e gratuito (custo R\$ 0, roda offline)** que prevê partidas de seleções, com foco na **Copa do Mundo 2026**. Entrega, para um confronto: **P(vitória/empate/derrota)**, **gols esperados (λ_A , λ_B)**, uma **banda de incerteza**, um leque de **mercados derivados** (over/under, ambos marcam, placares, dupla chance, handicap, quem marca primeiro) e um **score de confiança**. Há também um **simulador Monte Carlo do torneio inteiro** (chance de título por seleção). Fontes: README.md, 00 - Projeto/CLAUDE.md, 00 - Projeto/MODELO_FINAL.md.

O princípio declarado e repetido é **“probabilidades, nunca certezas”**, e o próprio projeto afirma que **não é ferramenta de aposta** (“Brier ~0,60 não é vantagem”, CLAUDE.md). Restrições inegociáveis (CLAUDE.md): custo zero, nada lê a internet no momento do cálculo (usa *snapshot* em disco), registro pré-jogo imutável, não inventar dados.

2.2 Como funciona — fluxo principal

O sistema é um **pipeline linear**, com os estágios se comunicando por tabelas SQLite (contrato de I/O por tabela):

```
ingest → elo_engine → features_pit → predictor → backtest_harness → report
martj42 Elo+σ_R forma+σ_dr λ→Poisson Brier/RPS/IC reliability
(CSV) (pré-jogo) (point-in-time) +Elo-direto +portão +ECE+banda
                                   →ensemble→V/E/D
```

1. **ingest.py** carrega o CSV do martj42 (resultados 1872–2026) para teams/matches, idempotente por natural_key.
2. **elo_engine.py** reconstrói o Elo cronologicamente e grava o **rating pré-jogo** de cada partida em match_ratings (a base do anti *look-ahead*).
3. **features_pit.py** monta *features* usando só jogos anteriores à data (forma recente ajustada a adversário → dr_{adj} , e σ_{dr}).
4. **predictor.py** converte dr em saldo $\text{GD} = \theta \cdot \text{dr}/100$ e total T_m , gera a **matriz Poisson** e a **leitura “Elo-direto” propagada**, e combina as duas num **ensemble**.
5. **backtest_harness.py** mede Brier/LogLoss/RPS com IC *bootstrap*, compara contra o **uniforme** e contra o **Elo público**, e implementa o **portão** estatístico.
6. **report.py** produz *reliability*/ECE e cobertura de banda.

A “porta da frente” para um confronto avulso é **predict_match.py** (usa o Elo atual de ratings_current); **web.py** é uma interface Flask local; **simulate.py** roda o Monte Carlo do torneio.

2.3 Módulos e como se relacionam

Há **boa separação** entre um **núcleo matemático puro** (funções lambdas/poisson_reads/elo_direct_read/p em predictor.py, sem I/O) e a **persistência** (os run()) de cada estágio, que leem e gravam SQLite). Os módulos de fator candidato (altitude, heat, estilo, dixon_coles, sigma_glicko, calibrate*) reusam predict + gate e ficam **atrás do portão**. predict_match/web/simulate reusam predict/lambdas/knockout_advance.

Módulo	Papel	Estado
ingest	martj42 → SQLite	ativo
elo_engine	Elo histórico + σ_R + rating pré-jogo	ativo (espinha dorsal)
features_pit	forma recente + σ_{dr} , <i>point-in-time</i>	ativo
predictor	$\lambda \rightarrow \text{Poisson}$ + Elo-direto → ensemble	ativo (núcleo)
altitude	termo GD_{alt} (McSharry)	adotado (passou o portão)
backtest_harness	métricas + IC + portão	ativo
report	reliability/ECE/coertura	ativo
predict_match	prever um confronto	ativo (porta da frente)

Módulo	Papel	Estado
simulate	Monte Carlo do torneio	ativo (insight)
registrar	registro prospectivo (register/settle/report)	mecanismo pronto, não usado
desfalques	Camada 3 (lesões/suspensões)	mecanismo pronto, magnitudes não calibradas
odds	3ª perna do ensemble (mercado)	encaixe pronto, sem dados
dixon_coles	correlação de placares	testado e rejeitado
sigma_glicko	σ guiado por dados	candidato OFF
heat, estilo	calor / tendência de gols	testados e rejeitados
xg	prior de estilo (StatsBomb)	esqueleto OFF
calibrate*	calibração de coeficientes/confiança	ferramentas
web	interface Flask local	ativo

3 2. Arquitetura

3.1 Organização de pastas

A **dupla natureza** está bem resolvida: um **vault Obsidian** para planejamento/documentação (00-06) e um **pacote Python** (scm_analytics/scm). A separação documentação ↔ código é limpa, e a **rastreabilidade é o ponto mais forte do projeto**: cada módulo cita no *docstring* a nota do contrato que implementa (ex.: `elo_engine.py` aponta 02 - Modelos/Elo.md e `camada1-planejamento-v5 §3.1`). Isto reduz o risco de o código divergir do contrato sem rastro — é uma prática rara neste porte.

3.2 Coesão e acoplamento

Coesão alta: cada módulo tem responsabilidade única e contrato de I/O por tabela. O núcleo matemático é testável sem banco (`tests/test_predictor.py` exercita `predict` diretamente). **Acoplamento baixo** no geral (estágios desacoplados via SQLite), com três pontos a observar:

- **Ciclo de import contornado em runtime.** `predictor.run()` importa `altitude.gd_alt` **dentro da função** (`predictor.py:256`, comentário “import tardio (evita ciclo predictor↔altitude)”). O ciclo existe porque `altitude.py` importa de `predictor` e de `backtest_harness`, que por sua vez importa de `predictor`. Funciona, mas sinaliza que a lógica de **predição** (produção) e a de **portão** (avaliação) estão entrelaçadas. O ideal seria um módulo `factors.py` (só os termos de λ) consumido pelo `predictor`, com os *gates* isolados no `harness`.
- **Coefficientes espalhados.** Não há camada única de configuração: parâmetros vivem em *dataclasses* por módulo (`PredictParams`, `EloParams`, `FeatureParams`) **mais** constantes soltas (`THETA_ALT` em `altitude.py`, `SIGMA_R_REF` em `predict_match.py`, `RD0/C_INFL` em `sigma_glicko.py`, `DRAW_CURVE` em `predictor.py`). Aceitável hoje; vira atrito quando a calibração precisar varrer tudo de forma coerente e versionada.
- **Schema é subconjunto do desenho, com colunas mortas.** Ver §4. O `db.SCHEMA` evoluiu (já tem `odds_hist` e `team_xg`), mas ainda faltam `venues/context/statsbomb` do design (03 - Dados/Esquema SQLite.md), e **há colunas declaradas que nunca são preenchidas** (`teams.confederation`, `teams.home_altitude_m`) — a altitude usa dicionários *hardcoded* em vez dessas colunas.

3.3 Escalabilidade

O ponto sensível é `features_pit.team_form`: para cada jogo roda duas subconsultas correlacionadas (forma do mandante e do visitante) filtrando por `time` e `date < t`. A v0.3 adicionou índices compostos (`home_team_id, date`) e (`away_team_id, date`) em `db.SCHEMA`, o que mitiga muito o custo. **[verificado]** Mesmo assim, **o re-backtest completo (49.431 jogos) excedeu 44 s** no meu ambiente — confirmando que este passo é o **gargalo** para reconstruções completas (irrelevante para a Copa, onde entram poucos jogos por rodada). A propagação determinística por estratos foi acelerada cacheando os quantis da Normal (`predictor._std_quantiles`) — boa otimização, mesma matemática.

3.4 Manutenibilidade

Alta: módulos pequenos (60–380 linhas), *docstrings* densos, nomes claros e consistentes em PT-BR, `from __future__ import annotations`. Custos residuais: conexões SQLite **sem context manager** (`db.connect`; vazam em caminhos de erro), **print() em vez de logging**, e a leitura “Elo-direto” reimplementada/derivada em mais de um lugar (mitigado pelo núcleo único `predictor.ved_from_eo`, D-43).

3.5 Melhorias arquiteturais sugeridas

1. **Extrair os termos de λ para `factors.py`** — quebra o ciclo de import e separa produção de avaliação.
2. **Evoluir `db.SCHEMA` para o `schema-alvo`** (`venues/context/odds/statsbomb`) **e usar as colunas que já existem** (`teams.home_altitude_m`) — destrava `xG/odds/desfalques` e elimina os dicionários *hardcoded*.
3. **Camada fina de configuração** para todos os coeficientes — viabiliza calibração coerente e versionada.

Veredito de arquitetura: sólida para o porte e — crucialmente — **suporta a evolução pretendida** (estágios desacoplados, contrato versionado, portão). O risco não está na arquitetura; está nos modelos e na consistência entre o que se valida e o que se entrega (§3, §6).

4 3. Modelos matemáticos (ênfase)

Esta é a seção central. Avalio cada bloco quanto a **correção aritmética, validade de modelagem e consistência entre o que é validado e o que é entregue**. As fórmulas estão **aritmeticamente corretas** — reproduzi as contas (Anexo A) —, mas há problemas de **modelagem** e de **degenerescência prática** (aparato que existe mas varia pouco).

4.1 3.1 Elo (elo_engine.py) — sólido, mas sem recência

$W_e(dr) = 1/(1 + 10^{-(dr/400)})$, $dr = R_A - R_B + \text{mando}$, K por competição (k_factor), G por margem de gols (g_factor , anti-saturação). Zero-soma. Conforme 02 - Modelos/Elo.md. **[verificado]**: $W_e(100) = 0,6401$, $W_e(300) = 0,8490$ — batem com o contrato.

Limitações reais:

- **Sem reversão à média nem decaimento por inatividade.** O rating é acumulado desde 1500 a partir de 1872 e **nunca regride**. Uma seleção que para de jogar mantém o rating; um histórico longo de vitórias infla o número. **[verificado]** na reconstrução: os valores absolutos ficam **~70-210 pontos acima** da convenção do elratings.net (Argentina 2210, Espanha 2188, França 2147), e aparecem **artefatos de ordenação — Colômbia (2086) acima do Brasil (2060)**, Marrocos no top-12. O invariante declarado “ ± 25 nas top-30” **não é medido em código** (elo_engine.main só imprime) e, pela reconstrução, **não é satisfeito**. Risco para a Copa: o dr de entrada de todo o modelo carrega esse viés de nível e de recência.
- **σ_R é função quase só de n .** $\sigma_r(n) = \text{floor} + (\text{prov} - \text{floor}) \cdot e^{-(n/\tau)}$ ($\text{floor}=40$, $\text{prov}=200$, $\tau=20$). Como as 48 seleções da Copa são estabelecidas, **todas convergem a $\sigma_R \approx 40$** — a incerteza de rating é praticamente constante entre elites (detalhe em §3.5 e Problema P-B).
- **k_factor por palavra-chave atribui $K=50$ a toda partida continental** (elo_engine.py:65-68), não só a finais, embora o *docstring* diga “finais continentais 50”. Fases de grupo de Euro/Copa América recebem K alto demais (Problema N6, baixo).

4.2 3.2 Poisson (predictor.poisson_reads/markets) — correto, mas independente

$M[i][j] = \text{Pois}(i; \lambda_A) \cdot \text{Pois}(j; \lambda_B)$, $i, j = 0..10$; V/E/D, over, BTTS e top-5 saem da matriz. **[verificado]** reproduz exatamente a execução manual $\text{IRN} \times \text{NZL}$ ($\lambda = 1,40/0,78$): **$P(V)=0,517$, $P(E)=0,275$, $P(D)=0,209$, $\text{over}2.5=0,372$, $\text{BTTS}=0,408$, $\text{soma} = 1,000000$** . Os mercados derivados (markets) saem da **mesma** matriz — não há modelo novo, o que é correto e honesto.

Duas ressalvas de modelagem:

- **Independência de gols.** Assume os gols dos dois times independentes; ignora a correlação negativa real (excesso de 0×0 e 1×1). Isso **enviesa BTTS/under** — exatamente o que a Dixon-Coles corrige. O projeto **mediu** o viés ($\text{BTTS} \approx +3,8$ pp, $\text{over} \approx +7$ pp) e **testou** a Dixon-Coles, mas ela foi **rejeitada pelo portão** (§3.8). O viés sistemático segue sem correção estrutural (Problema P-A).
- **Mercados derivados Poisson-condicionais.** A diagonal soma o $P(E)$ **da Poisson**, não o do ensemble (declarado, achado A1). É uma decisão coerente, mas significa que o V/E/D entregue (ensemble) e o V/E/D implícito nos placares (Poisson) **não são idênticos** — uma fonte de confusão para o usuário.

4.3 3.3 Curva de empate C1 (predictor.draw_prob) — corrigida, mas in-sample

O contrato (camada1-apositivo-formas-v5 §3) exige $P_E(dr)$ como **tabela empírica do martj42 por faixa de $|dr|$ e proíbe** o *proxy* fechado da auditoria v5. **[verificado]** que a v0.3 implementou a tabela empírica congelada predictor.DRAW_CURVE ($\text{draw_prob}(0)=0,2847$,

$\text{draw_prob}(100)=0,2629$, $\text{draw_prob}(300)=0,1942$) — diferente do proxy antigo. Correção real e confirmada.

Achado novo (metodológico). A `DRAW_CURVE` é **global e ajustada no conjunto inteiro** ($n=49.423$), inclusive nos jogos que depois são **avaliados** no backtest. Enquanto o Elo e a forma são *point-in-time* (anti *look-ahead*), a curva de empate **não é** — é um leve **vazamento in-sample** na componente $P(E)$. O efeito provável é pequeno (a curva tem poucos graus de liberdade), mas é uma inconsistência com o rigor PIT do resto do pipeline e **deveria ser declarada** (não encontrei essa ressalva na documentação).

4.4 3.4 Saldo $f(dr)$, total $g(dr)$ e o piso de λ — forma linear inválida no tail

$GD = \theta \cdot dr/100$ ($\theta=0,45$) e $T_m = (T_{\text{base}} + \kappa \cdot |dr|/100) \cdot \text{estilo} \cdot \text{heat}$ ($T_{\text{base}}=2,6$, $\kappa=0,10$) — formas lineares, *placeholders* do apêndice, confirmadas como quase ótimas pela calibração (D-17).

Problema (P-D): a forma linear faz $\lambda_B = (T_m - GD)/2$ **ficar negativo** no tail. **[verificado]:**

dr	GD	T_m	λ_B bruto	λ_B com piso	$\lambda_A + \lambda_B = T_m?$
500	2,25	3,10	+0,425	0,425	sim
740	3,33	3,34	+0,005	0,150	sim
900	4,05	3,50	-0,275	0,150	sim
1100	4,95	3,70	-0,625	0,150	sim

O piso ($\lambda_{\text{min}}=0,15$) trava λ_B **conservando o total** T_m (correto). Mas a forma linear é **fisicamente inválida** no tail e, a partir de $dr \approx 740$, **é o piso que faz a modelagem**, não o modelo. Confrontos plausíveis da Copa ($dr \approx 500-600$ entre uma elite e um estreante) já operam perto da borda de validade. A forma **saturante** $f_{\text{sat}} = GD_{\text{max}} \cdot \tanh(dr/dr_{\text{escala}})$, **já especificada no apêndice**, resolveria isto sem clamp — segue não adotada.

4.5 3.5 Incerteza e propagação (`features_pit + predictor.elo_direct_read`) — elegante, parcialmente inerte

A propagação é **determinística por estratos de igual probabilidade** (sem RNG, reprodutível) e está **correta: [verificado]** encolhe o favorito (efeito de Jensen — W_e é côncava para $dr>0$) e mantém $P \in [0,1]$ por construção, com banda nos percentis 16/84. **Mas o insumo é parcial e degenerado:**

- O contrato (§3.12) define σ_{ajuste} com **5 termos** (desfalque-dúvida, meio-tier, desvio de forma, fuso, descanso); o código implementa **só** $c \cdot \text{desvio_forma}$ (`features_pit`, $\sigma_{\text{ajuste_c}}=80$). Fuso/descanso/desfalque-dúvida **não entram**.
- A base σ_R **satura em ~40** para toda seleção estabelecida; o multiplicador vol_mult (clamped em $[0,6; 1,6]$) **atenua, não elimina** a degenerescência. Resultado: banda e confiança variam pouco **justamente entre as elites que disputam o título** (Problema P-B).
- **Achado novo (gateado):** o próprio `sigma_glicko.gate_band` revela que a banda atual **sobre-cobre** (~92% vs 68% nominal). Ou seja, a incerteza está **larga demais na média** — e ainda assim **sub-cobre** na faixa de favoritos fortes $[0,8-0,9]$ (§3.9). As duas coisas convivem: banda larga no agregado, estreita demais onde o favorito é forte.

4.6 3.6 Ensemble (`predictor.predict`) — diversidade redundante

Pesos sem-odds **0,56 Poisson / 0,44 Elo** (no histórico não há perna de mercado). **Achado central:** as duas leituras **derivam do mesmo escalar dr** — `poisson_reads` usa λ_A/λ_B que vêm de $gd_{\text{of}}(dr)/tm_{\text{of}}(dr)$, e `elo_direct_read` usa dr diretamente. Logo, **são duas projeções da mesma fonte**, não dois modelos independentes. **[verificado]:** em $dr=200$, $P(V)_{\text{Poisson}}$ e $P(V)_{\text{Elo}}$ sobem **juntas** com dr . A própria nota 02 - Modelos/Ensemble.md admite que “a diversidade real vem do mercado”. Conclusão: a “combinação de modelos”, central no design, é hoje **cosmética na**

validação — e isso explica em boa parte por que o ganho sobre o Elo é pequeno (\$3.10). Os pesos *com odds* (0,45/0,35/0,20) **nunca foram validados** (não há odds no histórico).

4.7 3.7 Altitude (altitude.py) — maior alavanca; adotada; ainda extrapolada

$GD_{alt} = \theta_{alt} \cdot (pen_B - pen_A) / 1000$, $pen = \max(0, alt_{sede} - alt_{casa})$, $\theta_{alt}=0,5$ (McSharry, BMJ 2007, base CONMEBOL). É o **único fator ambiental que passou o portão** (+0,049 de Brier, IC [+0,028, +0,070] em 554 jogos). Confirmei a cobertura para 2026 (Guadalajara/Zapopan 1566 m, normalização de acentos via `_norm`). Ressalvas que **permanecem**:

- **Magnitude grande e θ extrapolado.** Um termo desloca $\lambda \approx 0,56$ de cada lado; $\theta=0,5$ é da **CONMEBOL** aplicado também à **CONCACAF**. O `gate_by_confederation` sustenta $\theta=0,5$ nas duas (CONCACAF mais fraco, IC [+0,001, +0,045]), mas não há θ por confederação.
- **Elevações *hardcoded*.** `CITY_ALT/TEAM_HOME_ALT` são dicionários pequenos no código (só 4 seleções “adaptadas”: Bolívia, Equador, Colômbia, México). **Qualquer grafia de cidade divergente do martj42 desliga a altitude silenciosamente.** E as colunas de schema que existiriam para isto (`teams.home_altitude_m`) **estão mortas**.
- **Risco de dupla contagem com o mando** em jogos do México em casa: +1,12 de altitude e +40 de mando se somam sem calibração conjunta (declarado, B2).
- **Achado novo (latente).** `altitude.py:94` usa a anotação `Optional[str]` **sem importar `Optional`**. Só não quebra porque `from __future__ import annotations` adia a avaliação das anotações; é um **bug latente** (qualquer introspecção de tipos, ou a remoção do `future import`, levanta `NameError`). Não foi apontado nas auditorias anteriores.

4.8 3.8 Fatores rejeitados — corretamente barrados pelo portão

`heat.py` (calor), `estilo.py` (tendência de gols), `dixon_coles.py` (correlação) e `calibrate_1x2.py` (recalibração) foram **construídos e barrados**: calor $\Delta Brier +0,0007$ (IC cruza zero), estilo $\Delta Brier -0,0008$ (cruza), Dixon-Coles $\rho_{MLE} \approx -0,06$ mas BTTS piora, recalibração $T^*=1,0$ (nada a corrigir). Isto é um **ponto forte com justificativa**: a disciplina descartou *features* plausíveis sem evidência por jogo. (Nota de rigor: o portão do estilo usa um único *cutoff* treino/teste, não PIT por jogo como o `features_pit` — aceitável para um candidato rejeitado, mas registre a diferença.)

4.9 3.9 Confiança (predict_match.confidence) — desenho bom, maturidade quase inerte

$conf = 100 \cdot reliab(p_{max}) \cdot maturidade(\sigma_R)$, com *reliab* isotônica do backtest (`calibrate_confidence`, PAV correto) e $maturidade = 1 - \min(0,5, \sigma_R/200)$. **Confirmei que a v0.3 passou a usar o σ_R escalado** (`predict_match.py:167, D-35`) — correção real. Mas como $\sigma_R \approx 40$ para todas as elites, a maturidade fica em **0,8 ± pouco**, e a confiança vira **quase pura função de p_{max}** . O conserto de σ chegou à confiança, mas o **problema de fundo (σ_R preso a n) limita o ganho** (Problema P-B).

4.10 3.10 Tamanho do sinal — verificação independente do resultado-título

Reconstruí o backtest no recorte de **torneios** (WC/Euro/Copa América), que é o critério de aceite do projeto. **[verificado]**:

Métrica (n=2.249 torneios)	Meu valor	Documentado (v0.3)
Brier do modelo	0,5592	0,5595
Ganho vs uniforme	+0,107 , IC [+0,092, +0,123]	+0,107
Ganho vs Elo público	+0,0038 , IC [+0,0011, +0,0066]	+0,0037, IC [+0,0009, +0,0066]

Ou seja: **o modelo bate o uniforme com folga e bate o Elo público com $IC > 0$** — o resultado-título é **reproduzível e honesto**. Mas o **edge sobre o Elo é minúsculo (+0,0038 de Brier)**. Em termos práticos, **quase todo o poder preditivo vem do Elo**; o aparato adicional (forma, propagação, ensemble, altitude fora dos jogos de altitude) acrescenta muito pouco. Isso é coerente com a literatura e com a própria admissão do projeto, mas precisa ficar claro: **o sistema é, em essência, um Elo bem-feito com uma camada fina de melhorias**.

4.11 3.11 Modelos estatísticos mais robustos (o que seria superior, e por quê)

Em ordem de custo-benefício, **tudo paramétrico e auditável** (respeitando a decisão D-02 de não usar ML opaco):

1. **Bivariate Poisson / Dixon-Coles** — captura a correlação negativa de gols e corrige o viés de BTTS/under de raiz. (O projeto testou a DC e rejeitou *como está*; vale revisitar com λ direcional, não só τ , e medindo placar exato, não só BTTS.)
2. **Modelo de força ataque/defesa (Maher 1982; Karlis-Ntzoufras)** como **prior não-Elo** — desacopla λ_A e λ_B do escalar único d_r e dá **diversidade real** ao ensemble (hoje redundante, §3.6). É a maior alavanca conceitual.
3. **Ratings com estado dinâmico (Glickman *state-space*, ou Elo com decaimento/recência)** — resolve a ausência de reversão à média (§3.1) e a degenerescência de σ_R (§3.5) de uma só vez. O `sigma_glicko.py` já é meio caminho.
4. **Distribuição de Skellam** para o saldo de gols, ou **Weibull-count / Conway-Maxwell-Poisson** para sub/sobre-dispersão — eliminam o *hack* do piso de λ (§3.4).
5. **Odds de fechamento como sinal** — a literatura é consistente: o mercado é o *benchmark* mais difícil de bater. O `odds.py` já tem o encaixe; falta o dado.
6. **Regressão isotônica/Platt do 1X2 por faixa** — corrige a superconfiança medida em [0,8–0,9] (Problema P-C). Barata (o projeto testou a versão global e rejeitou; a **por faixa** é diferente).

Bayes hierárquico daria *shrinkage* elegante (e resolveria amostras pequenas por seleção), mas o projeto o rejeita por auditabilidade/overfit (D-02) — decisão legítima. **Nenhuma das sugestões 1-6 exige ML opaco.**

5 4. Fontes de dados

Inventário declarado (03 - Dados/Fontes gratuitas.md): martj42 (resultados), fixturedownload (calendário), StatsBomb (xG/bola parada), Open-Meteo (clima/altitude), Wikidata (elevação/técnico), eloratings.net (benchmark), Kalshi/Polymarket (mercado).

O que está realmente em uso. [verificado]: apenas o martj42 é ingerido (ingest.py, MARTJ42_URL). A altitude usa **tabelas hardcoded**, não Open-Meteo. O calor usaria climatology.json (presente em dados/), mas foi rejeitado. Nenhuma das demais fontes (fixturedownload, StatsBomb, Wikidata, odds) está integrada ao pipeline. **A base efetiva do sistema é uma única fonte de resultados brutos.**

Qualidade / cobertura / atualização.

- **martj42** é base reconhecida e ampla (49.431 jogos ingeridos; 44 pulados sem placar — ingest corretamente ignora fixtures futuras). Mas é **resultado bruto**: sem xG, sem escalões, sem minuto de gol, sem árbitro. Inclui entidades extintas (Iugoslávia etc.), ruído para o benchmark.
- **Cobertura temporal** vai a 1872; o Elo é reconstruído desde 1500. Jogos do séc. XIX inflam a métrica “todos os jogos”; por isso o recorte honesto é **torneios** ($n \approx 2.249$), corretamente usado como aceite.
- **Atualização** é por *snapshot* manual (ingest --download) — coerente com “roda local”, mas **sem automação**: exige re-rodar o pipeline antes de cada rodada da Copa.
- **Benchmark de Elo** contra eloratings.net é **manual e nunca automatizado**; **[verificado]** os ratings têm artefatos (Colômbia > Brasil; valores ~70-210 pts acima do eloratings) — o invariante “ ± 25 top-30” não é medido nem satisfeito (Problema P-M).
- **Reprodutibilidade do artefato**. O dados/scm.sqlite entregue **não pôde ser lido** neste ambiente (“disk image is malformed”). O copa2026.json **está presente e preenchido** (12 grupos $\times$ 4, hosts, altitude_venues) — uma melhoria desde a auditoria anterior, que o reportava ausente. Mesmo assim, depender de um SQLite binário gerado é frágil; o caminho reprodutível é **gerar do CSV** (como fiz).

Informações faltantes que mais melhorariam a precisão (em ordem de impacto):

1. **Escalações/desfalques estruturados** — o maior fator de curto prazo num jogo; hoje só via JSON manual, e com um **erro direcional** (§6, Problema N-A).
2. **xG histórico (StatsBomb)** — prior de estilo muito menos ruidoso que gols brutos; habilita o piso de bola parada.
3. **Odds/mercado de fechamento** — sem elas o ensemble não tem diversidade real (§3.6) e falta o comparador de mercado do aceite.
4. **Elevação por sede + altitude-de-casa das 48 via Open-Meteo** — substitui os dicionários *hardcoded* e cobre todas as sedes/seleções.
5. **Minuto do gol** (goalscorers.csv) e **sede/horário por jogo** — habilitam “tempo do gol” e calor/fuso reais.

6 5. Qualidade do código

Boa no geral; é um projeto bem cuidado. Por critério:

- **Organização / legibilidade:** alta. Módulos curtos, *docstrings* que citam o contrato, nomes consistentes, `from __future__ import annotations`.
- **Modularização:** boa (núcleo puro × I/O; contratos por tabela). Núcleo único `ved_from_elo` evita as 3 cópias antigas da leitura Elo-direto.
- **Repetição:** `P(V/E/D)` é recomputado em `predictor.markets` além de `poisson_reads`; aceitável.
- **Tratamento de erros:** adequado nas bordas (arquivo ausente → mensagem e `exit 1`; time não encontrado → sugestão por `difflib`). **Conexões SQLite sem *context manager*** (vazam em erro); **print em vez de logging**.
- **Tipagem:** parcial; *dataclasses* `frozen=True` para parâmetros (bom). **Sem checagem estática (mypy)** — e há ao menos um **import de tipo ausente não detectado** (`altitude.py:94, §3.7`).
- **Performance:** *bootstrap* vetorizado (numpy); propagação cacheada. Gargalo em `features_pit` no re-backtest completo (§2).
- **Segurança:** superfície mínima (local, sem rede no cálculo). `web.py` escuta só em `127.0.0.1`, `debug=False`, SQL **parametrizado** em todo o código (sem injeção evidente). `ingest --download/heat --build-climatology` usam rede, isolados e opcionais. Nenhum segredo no repo.
- **Testabilidade:** alta — **128 funções de teste em 25 arquivos**, sem rede, determinísticas, com `:memory:` e agora `conftest.py` (P-I parcialmente resolvido). **Limitação importante:** os testes cobrem sobretudo **invariantes** (anti *look-ahead*, coerência `[0,1]`, soma 1, lógica do portão) e **reprodução das próprias fórmulas** (`test_poisson_reproduces_manual` compara o código a um cálculo manual feito com a **mesma** Poisson independente). Garantem **estabilidade**, não **validade de modelagem** — nenhum teste detecta as divergências de §3 ou o erro de desfalques de §6, porque são “comportamento implementado”, não *bug* local.

7 6. Regras de negócio

Verifiquei se o que está codificado representa o domínio (futebol de seleções / Copa):

- **Mando = 0 em sede neutra; anfitrião com bônus.** Conceito correto e bem fundamentado (jogos-fantasma da COVID → mando é majoritariamente viés de árbitro/torcida; 02 - Modelos/Mando de campo.md). **Mas:** $H_{host2026} = +40$ **nunca passou pelo portão** (não há conjunto de calibração de Copa em co-anfitrião); é juízo declarado (Problema P-E). O `gate_by_confederation` e o D-47 estimam H empírico $\approx 110-120$ Elo de mando histórico, e o motor usa 100 — coerente.
- **Forma recente** — regra correta (ajuste curto-prazo ao Elo, ajustado a adversário, cap ± 30). **[verificado]** que a porta da frente **agora aplica a forma** (`predict_match.py:128, dr = elo_A - elo_B + (forma_A - forma_B) + mando, D-34`) — corrige a divergência produção↔backtest que a auditoria anterior apontou como **crítica**. Bom.
- **Desfalques direcionais — ERRO DIRECIONAL CONFIRMADO (achado novo).** O contrato (02 - Modelos/Desfalques direcionais.md) é explícito: ausência no **ataque** deve **cortar λ do próprio time (δ_{ata}), NÃO inflar o rival**; ausência na **defesa/goleiro** entra via `dr`. A implementação (`desfalques.match_deltas + hook` em `predict_match.py:144-145`) roteia a penalidade de ataque pelo **canal de GD** ($ga += gd_desf$), e o GD é **soma-zero sobre λ** ($\lambda_A = (T_m + GD)/2$, $\lambda_B = (T_m - GD)/2$). **[verificado]:** com o atacante-chave do mandante fora, $gd_delta = -0,25 \rightarrow \lambda_A$ cai de 1,850 para 1,725 **mas λ_B do adversário SOBE de 0,950 para 1,075 (+13%)**. Ou seja, **a implementação faz exatamente o que o contrato proíbe:** inflar o rival. Além disso, as magnitudes (35/15/5 Elo; 0,25/0,12/0,04 gols) são *placeholders* **nunca gateados**. Severidade Média (Alta para previsão de jogo real).
- **Formato e chaveamento da Copa 2026** — `simulate.py` codifica o **chaveamento oficial da FIFA** (R32 73-88 → final 104) e aloca os 8 terceiros por elegibilidade do Anexo C com *backtracking*, validado nas 495 combinações em teste. **Excelente fidelidade ao regulamento.** Simplificação declarada: desempate de grupo `pts` → `saldo` → `gols pró` → `moeda`, com um ajuste de confronto direto **só entre vizinhos adjacentes** (`_sim_group:184-188`) — não reproduz a mini-tabela H2H de empates triplos da FIFA. Efeito pequeno.
- **Altitude no torneio — [verificado]** que a v0.3 aplica `gd_alt` nos jogos de **grupo** do anfitrião (D-37, `alt_venues`), mas **deliberadamente não no mata-mata** (declarado, D-48: a altitude vazava e inflava o México). Defensável (sedes de mata-mata variam), mas significa que eventuais jogos do México em altitude no mata-mata ficam subestimados.
- **Mata-mata / pênaltis** — `knockout_advance: avanço_A = P(V) + P(E) \cdot (0,5 + \epsilon \cdot sinal(dr))`, $\epsilon=0,03$. **[verificado]** soma exatamente 1. Conceito correto. Ressalva menor: usa `sinal(dr)`, não a magnitude — um favorito por 1 ponto de Elo recebe a **mesma** vantagem de desempate ($\epsilon=0,03$) que um favorito por 500 pontos.
- **Registro pré-jogo imutável** — regra correta e essencial. **A execução é manual e o laço está aberto:** o registro-previsoes.csv tem **9 linhas preenchidas à mão**, com versões inconsistentes (v0.1-manual, v2.0-manual, v5.0-manual, v3.0-prelim) e **sem coluna de resultado** → **zero validação prospectiva fechada** até agora. O módulo `registrar.py` (`registrar/settle/report`) existe, mas **não está sendo usado** para gerar/fechar o registro (Problema P-G).

8 7. Problemas encontrados

Severidade: **Crítica** (compromete a validade do que o sistema afirma) · **Alta** · **Média** · **Baixa**.
 Origem: **Novo** = achado desta auditoria; **Aberto** = confirmado ainda em aberto no código atual.

#	Problema	Grav.	Origem	Local	Impacto	Como corrigir
N-A	Desfalque de ataque infla o λ do rival (canal de GD é soma-zero), contrariando o contrato (“não inflar o rival”)	Média	Novo	desfalques.match_goals, 3 predict_match.py:142-145	A Ganha 3 pontos por efeito direcional errado ; o azarão “ganha” gols quando o favorito perde um atacante	Cortar λ próprio por um termo multi-plicativo $\lambda_A \cdot (1 - \delta_{ata})$ (contrato §8 passo 6), fora do canal GD; gatear magnitudes
N-B	Curva de empate C1 ajustada in-sample (global, nos mesmos jogos avaliados) — quebra o rigor PIT do resto	Média	Novo	predictor.DRAW_CURVE build_draw_curve.py	Overfitismo P(E) do backtest; inconsistência metodológica não declarada	Ajustar a curva só no treino (date < cutoff) ou declarar a ressalva
N-C	Optional usado sem import em altitude.py	Baixa	Novo	altitude.py:94	Bug latente (mascarado por from __future__); quebra sob introspecção de tipos/mypy	from typing import Optional
N-D	Colunas de schema mortas: teams.confederation/home_altitude_m nunca preenchidas; altitude usa dicts <i>hardcoded</i>	Baixa	Novo	db.SCHEMA; ingest; altitude.CITY_ALTITUDE	Grafia divergente ENGINE_ALTITUDE em silêncio; dado não rastreável	Popular as colunas no ingest/seed e ler delas em altitude
N-E	K=50 para toda partida continental (não só finais)	Baixa	Novo/Aberto	elo_engine.k_falcos, 66 68	Jogos de grupo de Euro/Copa América recebem K alto → ratings levemente enviesados	Detectar fase “final/decisão” ou rebaixar continental de grupo a K=40
P-A	Poisson in-dependente / sem Dixon-Coles; ensemble sem diversidade real (Poisson e Elo do mesmo dr; mercado=0)	Alta	Aberto	predictor.poisson_under/predict	BTTs/under; “combinação de modelos” redundante → edge sobre Elo pequeno (+0,0038)	DC com λ direcional + membro de prior não-Elo (ataque/defesa/xG) e/ou odds; revalidar pesos
P-B	σ_R estruturalmente função de n (satura ~40); banda/confiança pouco informativas entre elites	Alta	Aberto	elo_engine.sigma_features_pit.vol_m	Onde mais importa (favoritos do título), incerteza é quase constante	Adotar sigma_glicko (já pronto) após o portão de banda, ou σ do erro de ajuste

#	Problema	Grav.	Origem	Local	Impacto	Como corrigir
P-C	Superconfiança Média em favoritos fortes [0,8-0,9] (obs 0,74 vs banda [0,84-0,92]) — medida, não corrigida	Média	Aberto	report.band_cov	Eventos daed Copa vivem nessa faixa; probabilidades altas demais	Recalibração isotônica/Platt por faixa (não global, já testada)
P-D	Forma linear de GD inválida no tail ($\lambda_B < 0$ antes do piso; piso faz a modelagem a partir de $dr \approx 740$)	Média	Aberto	predictor.lambda	Correções desiguais da Copa (dr 500-600) operam perto da borda de validade	Adotar forma saturante tanh (já no apêndice), decidida no backtest
P-E	Mando do anfitrião +40 nunca passou pelo portão	Média	Aberto	MODELO_FINAL; pre-dict_match --mando	Número-chave para 3 anfitriões em 2026 é juízo, não medida	Montar conjunto de calibração de co-anfitrião e gatear mando×altitude juntos
P-F	Camada 3 (desfalques) sem dados nem calibração (além do erro N-A)	Média	Aberto	desfalques.py (magnitudes placeholder)	Sistema não considera o maior fator de curto prazo de forma confiável	Base de escalações + portão das magnitudes
P-G	Zero validação prospectiva fechada — registro manual, 9 linhas, sem coluna de resultado	Média	Aberto	03 - Dados/registo-previsoes.csv; registrar.py não usado	Nenhum Brier-prospectivo real medido; previsões manuais ≠ código	Gerar o registro pelo registrar/predict_match (carimba versão/hash) e preencher resultados
P-H	Schema ainda subconjunto (sem venues/context/statsbomb)	Média	Aberto	db.SCHEMA vs Esquema SQLite.md	Bloqueia xG/contexto; evolução planejada não “encaixa” sem migração	Evoluir o schema para o alvo antes da Camada 3+
P-M	Benchmark de Elo não automatizado; ratings com artefatos (Colômbia>Brasil; valores inflados; sem recência)	Média	Aberto	elo_engine (sem reversão/decaimento)	dr de entrada de todo o modelo carrega viés de nível e recência	Decaimento/recência no Elo; script de comparação vs snapshot eloratings
P-I	Faxina: SQLite sem context manager; print vs logging; sem mpy	Baixa	Aberto	db.connect; vários main	Manutenção/robust	Context managers; logging; mpy em CI
P-J	Dependências não pinadas ($\geq$) apesar de TECH_STACK dizer “pinadas”	Baixa	Aberto	requirements.tx	Reprodutibilidade frágil no tempo	Pinar versões exatas ($\equiv$) ou lock

#	Problema	Grav.	Origem	Local	Impacto	Como corrigir
P-K	Documentação inconsistente: contagens de teste ("73/86/92"; há 25 arquivos/128 funções) e deriva de versão (CLAUDE.md cita v0.2; código é v0.3)	Baixa	Aberto	README.md, CLAUDE.md	Confunde novos leitores/agentes	Reconciliar contagens e versão
P-N	Artefato scm.sqlite ilegível neste ambiente (<i>disk image malformed</i>)	Baixa	Novo	dados/scm.sqlite	Não foi possível validar o binário entregue; reprodução só via CSV	Não versionar o binário; documentar a geração do DB

9 8. Melhorias (priorizadas por impacto)

Prioridade 1 — consistência e validade (antes de confiar em qualquer número):

1. **Corrigir o erro direcional dos desfalques (N-A)** — é um *bug* de regra de negócio que produz o efeito oposto ao pretendido. Barato e de alto impacto na credibilidade da Camada 3.
2. **Fechar o laço prospectivo (P-G)**: gerar o registro pelo registrar, carimbar versão/hash e preencher resultados → o **primeiro Brier prospectivo real** da Copa. É o único caminho para saber se o sistema funciona **fora de amostra**.
3. **σ informativo de verdade (P-B)**: adotar `sigma_glicko` (já pronto) após o portão de banda, e **encolher** a banda agregada que sobre-cobre. Destrava banda/confiança, hoje quase inertes.
4. **Declarar/corrigir o in-sample da curva de empate (N-B)** e o benchmark de Elo (P-M).

Prioridade 2 — precisão e robustez do modelo:

5. **Diversidade real no ensemble (P-A)**: membro de **prior não-Elo** (ataque/defesa/xG) e/ou **odds**; visitar Dixon-Coles com λ direcional. É o que pode **crescer o edge** de +0,004 para algo material.
6. **Forma saturante de GD (P-D)** no tail e **recalibração isotônica do 1X2 por faixa (P-C)**.
7. **Reversão à média / recência no Elo (P-M)** — corrige o viés de nível na própria espinha dorsal.
8. **Gatear mandoxaltitude juntos e por confederação (P-E, §3.7)**.

Prioridade 3 — dados e domínio:

9. **Camada 3 com dados reais (P-F)** após corrigir N-A.
10. **Evoluir o schema (P-H)** e integrar **odds** quando houver captura; **automatizar o snapshot** (rodada a rodada).

Prioridade 4 — qualidade/manutenção: import de Optional (N-C), colunas mortas (N-D), K continental (N-E), context managers, logging, mypy, pinagem, reconciliar documentação (P-I/J/K).

Sobre estatística: o maior retorno **não** é adicionar fatores — a v5 já tem fatores demais para a amostra (o risco nº 1 declarado em `camada1-planejamento-v5` §16). É **fortalecer o baseline, a consistência e a validação**: produção = backtest, σ informativo, diversidade real e validação prospectiva.

10 9. Funcionalidades futuras (com justificativa)

Pensando em previsão/análise da Copa 2026. (O simulador de torneio e o mata-mata já foram entregues.)

1. **Validação prospectiva ao vivo com placar real** — um painel que, a cada rodada, registra a previsão pelo código antes do jogo e calcula o Brier prospectivo acumulado vs uniforme/Elo/mercado. *Justificativa:* é a única evidência **fora de amostra**; transforma “insight” em “sistema medido”. É também o item nº 1 do roadmap.
2. **Membro de modelo independente (ataque/defesa ou xG)** no ensemble. *Justificativa:* hoje o ensemble é redundante (§3.6); um prior não-Elo é o que pode dar diversidade real e crescer o edge.
3. **Comparador de mercado** (Kalshi/Polymarket por captura manual com *timestamp*) na interface. *Justificativa:* o próprio projeto define mercado como *benchmark*; expor onde o modelo concorda/ diverge é honesto e prepara a 3ª perna do ensemble.
4. **Explicador de previsão** (“por que este número”): decompor `dr` em Elo/forma/altitude/mando/desfalque e mostrar a sensibilidade. *Justificativa:* auditabilidade é valor central; o `predict_match` já calcula as parcelas (`dr_desf`, `gd_alt`), falta expor.
5. **Cenários de classificação** (“quem precisa de quê na última rodada”) + *flag* de jogo-morto. *Justificativa:* captura motivação/rotação sem fingir prever o imprevisível.
6. **Backtest dirigido de 2018/2022 vs previsor público** (ex.: Opta/FiveThirtyEight) como teto externo. *Justificativa:* dá um comparador acima do Elo/uniforme — hoje o único “adversário” é o Elo, que o modelo mal supera.
7. **Mercado de placar exato + “tempo do gol”** (ao ingerir `goalscorers.csv`) com base Dixon-Coles. *Justificativa:* completa a oferta de mercados com base correlacionada correta.

11 10. Roadmap (ordem de prioridade)

Fase 0 — Corrigir e fechar o laço (antes de confiar em qualquer número). *Sem isto, o resto é decoração.*

- Corrigir o **erro direcional dos desfalques** (N-A) e o **import** (N-C).
- **Iniciar o registro prospectivo gerado por código** (P-G) — a Copa está em andamento; cada rodada não registrada é dado perdido.
- Declarar/corrigir o **in-sample da curva de empate** (N-B).

Fase 1 — Núcleo estatístico.

- **σ guiado por dados** (Glicko, já pronto) + **encolher a banda** que sobre-cobre (P-B).
- **Forma saturante** (P-D) e **recalibração isotônica por faixa** (P-C).
- **Recência/reversão no Elo** (P-M) e **gatear mando $\times$ altitude** (P-E).

Fase 2 — Precisão de modelo.

- **Prior não-Elo** no ensemble (ataque/defesa/xG) — diversidade real (P-A).
- **Camada 3** com dados e magnitudes gateadas (P-F).

Fase 3 — Produto/valor.

- **Comparador de mercado + explicador de previsão** na interface.
- **Backtest vs previsor público** como teto externo.

Fase 4 — Infra/manutenção (contínuo).

- Evoluir schema e usar colunas mortas (P-H, N-D), faxina (P-I), pinagem (P-J), reconciliar doc/versão (P-K, N-E), benchmark de Elo automatizado (P-M).

Pode esperar (corretamente despriorizado pelo projeto): afinação fina de pesos do ensemble (só com ≥ 30 jogos), xG ao vivo das 48 (sem fonte), árbitro individual (lacuna declarada).

12 11. Conclusão

12.1 Pontos fortes (com justificativa técnica)

- **Disciplina de processo rara:** contrato matemático congelado (v5.0), decisões registradas como ADRs (Decisoes tecnicas), múltiplas rodadas de auditoria, fatores ancorados em literatura. A rastreabilidade **nota** → **fórmula** → **módulo** é exemplar.
- **Portão estatístico que realmente barra.** O IC-*bootstrap*-pareado-de- Δ Brier-que-não-cruza-zero (backtest_harness.gate) está **correto** e **[verificado]** reproduz a rejeição de calor/estilo/Dixon-Coles e a adoção de altitude. Rejeitar *features* plausíveis por falta de evidência por jogo é honestidade metodológica que quase nenhum projeto pratica.
- **Point-in-time levado a sério** no Elo e na forma (rating pré-jogo persistido; teste anti *look-ahead* dedicado).
- **O resultado-título é reproduzível: [verificado]** o modelo bate o uniforme com folga e **bate o Elo público com IC > 0** (+0,0038 de Brier em torneios). É a diferença entre “tem sinal” e “supera o piso trivial”.
- **Engenharia limpa, local, R\$ 0**, com 128 testes determinísticos e coerência [0,1] por construção.

12.2 Pontos fracos (com justificativa técnica)

- **O “modelo” é, em essência, um Elo bem-feito.** Todo o dr — e dele ambas as λ e a leitura Elo-direto — vem de um **único escalar**; o ensemble combina **duas projeções da mesma fonte** (§3.6) e a Poisson é independente (§3.2). Por isso o **edge sobre o Elo é minúsculo** (+0,0038). O aparato (forma, propagação, ensemble) acrescenta pouco mensurável.
- **Aparato de incerteza parcialmente inerte:** σ_R preso a n (satura ~ 40), banda que **sobre-cobre no agregado** mas **sub-cobre nos favoritos fortes** (§3.5, §3.9).
- **A forma linear de λ é inválida no tail** e, a partir de $dr \approx 740$, é o **piso** que modela (§3.4).
- **Lacunas de domínio para a Copa:** desfalques com **erro direcional** (N-A) e sem dados, mando do anfitrião não gateado (P-E), altitude extrapolada para a CONCACAF (§3.7).
- **Validação prospectiva ainda zero** (P-G), com a Copa **já em andamento** — a janela está passando.

12.3 O que mais chamou a atenção

O **contraste entre a qualidade do planejamento e o tamanho real do sinal entregue**. O projeto construiu um aparato sofisticado (propagação de incerteza, ensemble, banda, confiança, simulador oficial da FIFA) sobre um **núcleo que, medido honestamente pelo próprio portão, mal supera um Elo**. Isso não é um defeito de execução — é o que a disciplina do portão **revela**: com os dados atuais (resultados brutos), o teto é esse. O segundo destaque é o **portão em si**, que continua sendo o melhor ativo do projeto: foi ele que barrou calor, estilo, Dixon-Coles e recalibração, e foi ele que me deixou **reproduzir e confirmar** o resultado-título. O terceiro foi descobrir, no código, um **erro direcional de regra de negócio** (desfalque de ataque inflando o rival) que contradiz o próprio contrato e passou por duas auditorias internas — um lembrete de que **testes de invariante não pegam erros de modelagem**.

12.4 Nível técnico

Engenharia e processo: alto. Modelagem estatística efetivamente entregue: médio — *baseline* correto e honesto, com comparador não-trivial, mas com diversidade de modelo redundante, incerteza parcialmente inerte, uma regra de negócio com sinal trocado, e um sinal de *skill* pequeno. É claramente trabalho de alguém competente e com forte cultura de honestidade metodológica; o teto atual vem da distância entre o que o contrato promete e o que os dados (uma única fonte de resultados) sustentam.

12.5 Preparo para análises da Copa 2026

- **Como ferramenta de estudo** que produz probabilidades 1X2 razoáveis e calibradas na média, com confiança honesta e simulador de torneio fiel ao regulamento: **utilizável, com ressalvas** — e respeitando o aviso do próprio sistema (“probabilidade, não certeza; não é recomendação de aposta”).
- **Como sistema de previsão sério da Copa: ainda não pronto.** Faltam, em ordem: (1) corrigir o erro de desfalques e fechar o laço prospectivo; (2) σ informativo e banda que signifique algo; (3) diversidade real de modelo para crescer o edge; (4) dados de jogo (escalações/odds/xG).

A arquitetura suporta essa evolução (estágios desacoplados, contrato versionado, portão). **Os modelos atuais não a sustentam** sem as Fases 0-1. A filosofia — *congela o contrato, mede com portão, nunca afirma certezas* — é a base certa; o que falta é **fazer o código honrar o contrato de ponta a ponta** (a começar pelos desfalques), **medir contra adversários à altura** (mercado, previsor público) e **fechar a validação prospectiva** enquanto a Copa acontece.

13 Anexo A — Verificações numéricas executadas

Reconstruí o pipeline a partir de dados/results.csv (martj42) num ambiente isolado (ingest → elo_engine → features → predictor → backtest) e reproduzi as fórmulas centrais. Resultados marcados [verificado] no corpo do documento.

Verificação	Resultado	Confere?
Ingestão martj42	49.431 jogos, 336 seleções, 44 pulados (sem placar)	sim
W _e (dr)	W _e (100)=0,6401; W _e (300)=0,8490	sim (contrato)
Poisson IRN×NZL ($\lambda=1,40/0,78$)	V=0,517 · E=0,275 · D=0,209 · over=0,372 · BTTS=0,408 · soma=1,000000	sim (reproduz test_predictor e a execução manual)
λ_B no tail sem piso	dr=740 → $\lambda_B \approx 0$; dr=900 → λ_B bruto -0,275; piso conserva $\lambda_A + \lambda_B = T_m$ exato	confirma P-D
Curva de empate (atual)	0,2847 (dr=0); 0,2629 (100); 0,1942 (300) — empírica, ≠ proxy antigo	confirma §3.3
knockout_advance soma	dr ∈ {-300, 0, 300}: adv _a +adv _b = 1,000000	confirma §6
Desfalque ataque (mandante)	atacante-chave fora → λ_A 1,850→1,725, λ_B (rival) 0,950→1,075 (+0,125)	confirma o erro N-A
Elo reconstruído (top)	Argentina 2210, Espanha 2188, Colômbia 2086 > Brasil 2060 ; valores ~70–210 acima do eloratings	confirma P-M
Backtest torneios (n=2.249)	Brier 0,5592; vs uniforme +0,107 IC[+0,092,+0,123]; vs Elo +0,0038 IC[+0,0011,+0,0066]	reproduz o resultado-título (v0.3)

Limitação: o features_pit completo (49.431 jogos) excedeu 44 s no ambiente; o backtest acima foi computado diretamente sobre o recorte de torneios (n=2.249) usando as mesmas funções do código (team_form, predict, gate, elo_baseline_read). O dados/scm.sqlite entregue não pôde ser lido (disk image malformed); todas as verificações partem do CSV.

Auditoria técnica independente — 20 de junho de 2026. Baseada na leitura integral do repositório (vault 00-06 + pacote scm_analytics/) e em verificação numérica das fórmulas centrais e do backtest. Sem implementação de funcionalidades. Conclusões citam arquivo/módulo; números marcados [verificado] foram reproduzidos em código.